Aula 43 — Big Data na Nuvem (Parte 2)

Computação em Nuvem e Virtualização

Ricardo Pasquati Pontarolli

Técnico em Redes de Computadores · IFSP Boituva · pasquati@ifsp.edu.br · v44

Objetivos da Aula

- Compreender o modelo **MapReduce** e o **Hadoop**.
- Conhecer **Spark** e o processamento em memória.
- Entender **pipelines de dados** e **ETL**.
- Identificar serviços gerenciados de Big Data.

Processamento Distribuído

- Dividir o trabalho em **muitas máquinas**.
- **Paralelismo** para processar dados em larga escala.
- Tolerância a falhas por **replicação**.
- Base: Hadoop, Spark e serviços gerenciados.

MapReduce

- Modelo de programação do Hadoop.
- **Map:** processa cada dado, gerando pares.
- **Reduce:** agrega os resultados.
- Divide-e-conquista em larga escala.

Hadoop

- Ecossistema de **armazenamento (HDFS)** e processamento (MapReduce).
- **YARN:** gerencia recursos do cluster.
- Amplamente usado em data lakes.
- Gerenciado na nuvem: **Amazon EMR**, Dataproc.

Apache Spark

- Processamento **em memória** — muito mais rápido.
- Suporta **batch, streaming, SQL e ML**.
- APIs em Python (**PySpark**), Scala, Java.
- Preferido para análises interativas e ML.

Pipelines e ETL

- **ETL:** Extração, Transformação e Carregamento.
- **ELT:** transformar dentro do destino (data warehouse).
- Ferramentas: AWS Glue, Azure Data Factory.
- Movem dados de fontes para análises.

Serviços Gerenciados

Necessidade	Serviço (exemplos)
Armazenamento	S3, GCS, Azure Blob
Processamento	EMR, Dataproc, Databricks
ETL	Glue, Data Factory
Streaming	Kinesis, Pub/Sub

Data Warehouse x Data Lake

- **Data lake:** dados brutos, flexível, barato.
- **Data warehouse:** estruturado, otimizado para consultas (Redshift, BigQuery).
- **Lakehouse:** combina ambos.
- Escolha conforme o **caso de uso**.

> **Note**
>
> **MapReduce** e **Spark** resolvem o mesmo problema de formas diferentes: Spark, em memória, tende a ser muito mais rápido para cargas interativas.

Resumo da Aula

- **MapReduce/Hadoop** introduziram o processamento distribuído.
- **Spark** acelera com processamento em memória.
- **ETL/ELT** movem e preparam os dados.
- Serviços **gerenciados** reduzem a operação na nuvem.

Atividade Rápida

- Explique as fases **Map** e **Reduce**.
- Cite vantagens do **Spark** sobre o MapReduce.
- Diferencie **data lake** de **data warehouse**.

Referências

- Apache Spark / Hadoop — *Documentação*.
- AWS EMR / Google Dataproc.

Próxima Aula

- **Aula 44:** Machine Learning na nuvem.