Aula 45 — Prática: Big Data e ML na Nuvem

Computação em Nuvem e Virtualização

Ricardo Pasquati Pontarolli

Técnico em Redes de Computadores · IFSP Boituva · pasquati@ifsp.edu.br · v44

Objetivos da Aula

- Aplicar um **pipeline de dados** na nuvem.
- Utilizar **armazenamento de objetos** e um serviço de processamento.
- Treinar ou usar um **modelo simples**.
- Consolidar Big Data + ML na prática.

Ambiente da Prática

- Conta em um provedor (camada gratuita é suficiente).
- **Armazenamento de objetos** para os dados (ex.: bucket).
- Serviço de processamento (ex.: notebook gerenciado).
- Biblioteca de ML (scikit-learn, pandas).

Passo 1 — Ingestão

- Obter um **dataset** público (CSV).
- Enviar para o **bucket** de armazenamento.
- Verificar permissões de acesso.
- Registrar origem e formato dos dados.

Passo 2 — Preparação (ETL)

- Ler os dados em um **notebook** na nuvem.
- Limpar: valores ausentes, tipos, duplicatas.
- Transformar: criar/ajustar variáveis.
- Salvar a versão **tratada** de volta no bucket.

Passo 3 — Análise/Modelagem

- Análise exploratória (estatísticas, gráficos).
- Dividir em **treino e teste**.
- Treinar um modelo simples (ex.: classificação/regressão).
- Avaliar com métricas (**acurácia, RMSE** etc.).

Passo 4 — Implantação (opcional)

- Salvar o **modelo treinado**.
- Expor como **API** ou endpoint gerenciado.
- Testar uma predição.
- Monitorar uso.

Verificação da Prática

- ☐ Dataset no armazenamento de objetos.
- ☐ ETL executado e versão tratada salva.
- ☐ Modelo treinado e avaliado.
- ☐ (Opcional) modelo implantado.

Tip

Mantenha **notebooks versionados** e nomeie os buckets/datasets de forma clara — isso é a base do **MLOps**.

Problemas Comuns

- Falta de permissão no bucket $\rightarrow$ revisar **IAM**.
- Dados "sujos" $\rightarrow$ dedicar tempo ao **ETL**.
- Modelo ruim $\rightarrow$ revisar **features** e algoritmo.
- Custo inesperado $\rightarrow$ desligar recursos ao terminar.

Resumo da Aula

- Montamos um **pipeline** ingestão $\rightarrow$ ETL $\rightarrow$ modelo.
- Usamos **armazenamento e computação** na nuvem.
- (Opcionalmente) implantamos o modelo.
- Próxima aula: **atividade** sobre Big Data e ML.

Referências

- AWS SageMaker / Google Vertex AI.
- scikit-learn — *Documentação*.

Próxima Aula

- **Aula 42:** Atividade — Big Data e Machine Learning.